Segmentação de chamadas de call center

Setor (supervisionado) e subgrupo dentro do setor (sem rótulo)

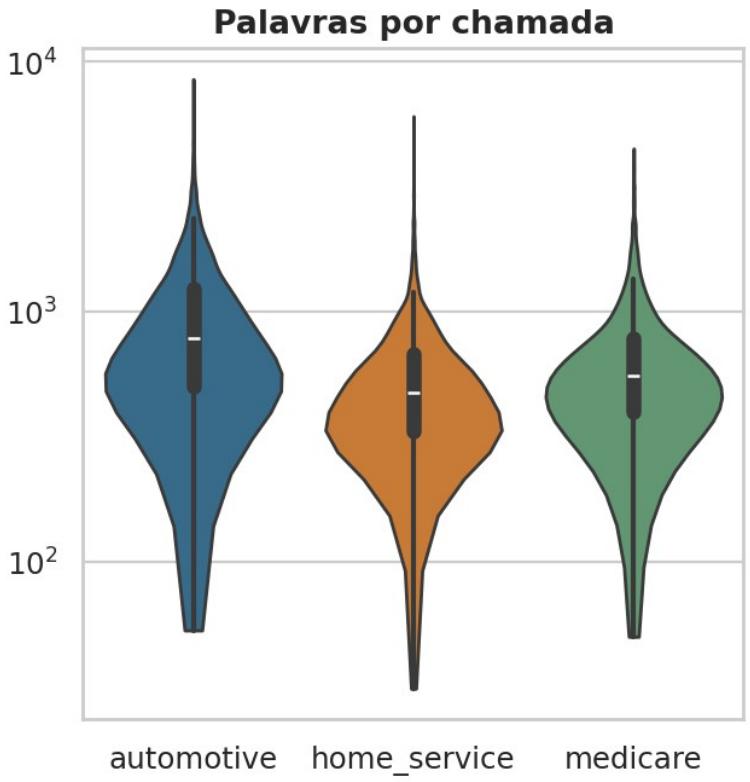
Entra a transcrição completa de uma chamada; saem o setor e o subgrupo.

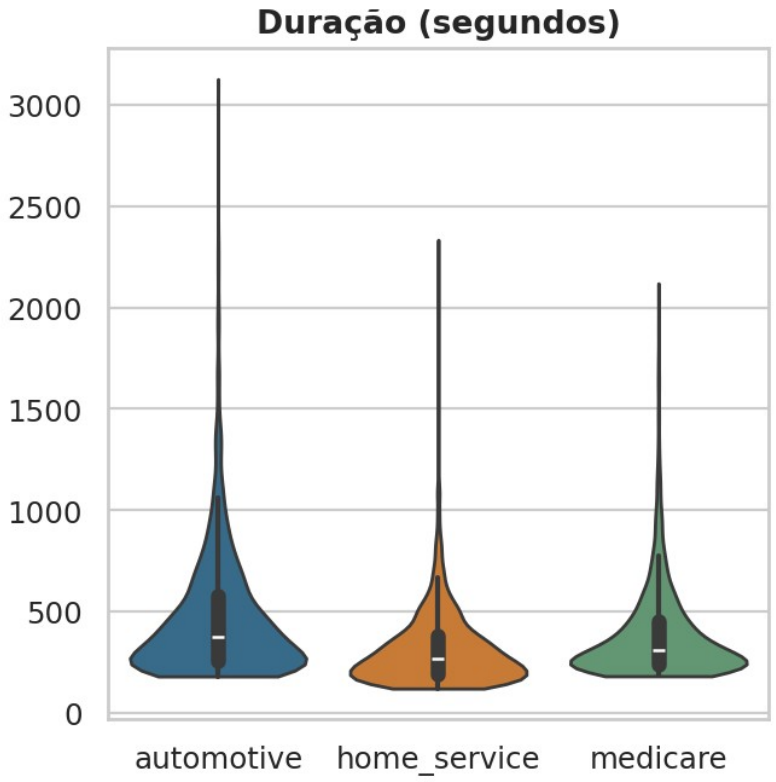
10.121 chamadas distintas em três setores: automotivo, home service e medicare.

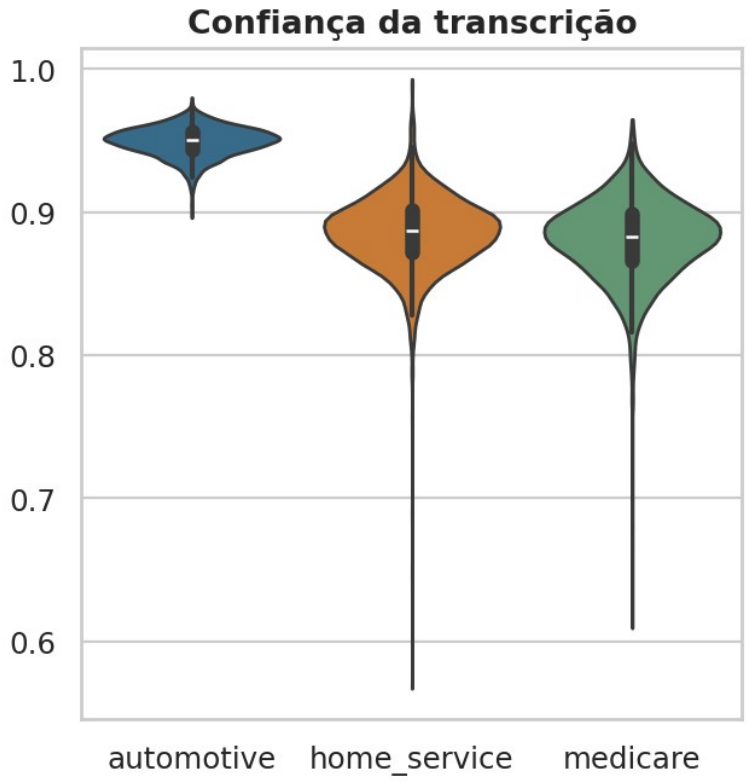
Caderno de experimentação, API, pipeline de retreino com portão de promoção, painéis e decisões documentadas.

O que há nos dados

Parte 2 do caderno: tamanho, duração, confiança da transcrição e vocabulário







Risco de vazamento: seis suspeitas, seis testes

Parte 3 do caderno

Teste	F1 macro
0. referência (texto completo)	99,35%
1a. divisão por arquivo (cópias soltas)	99,29%
1b. divisão por chamada	99,35%
2. só metadados	71,08%
2b. só confiança da transcrição	64,27%
2c. só duração	42,37%
3. sem marcadores [TAG]	99,32%
4a. só as primeiras 60 palavras	95,41%
4b. só as últimas 60 palavras	81,65%
4c. sem as primeiras 60 palavras	98,37%
5. rótulos embaralhados	33,07%

Como o setor foi medido

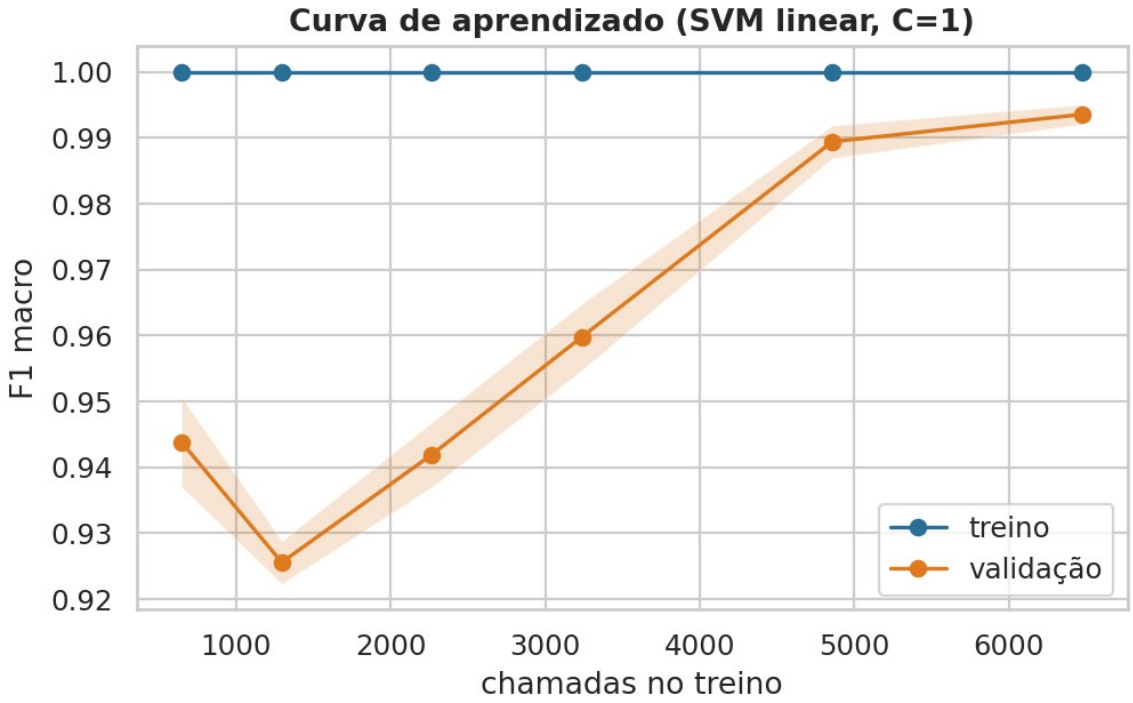
Desenvolvimento em validação cruzada de 5 dobras; teste aberto uma única vez

Desenvolvimento: 8.094 chamadas; teste: 2.027.

Referência na validação cruzada: F1 macro 99,35%.

Sobreajuste e subajuste vistos nas curvas de validação e de aprendizado.

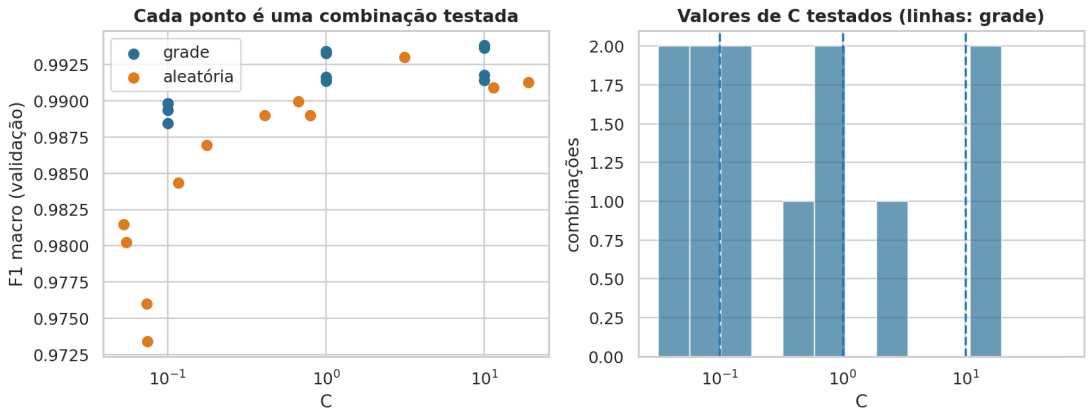
Cada chamada só aparece de um lado (grupos por texto idêntico).



Busca de hiperparâmetros: aleatória contra grade

Mesmo orçamento de combinações; depois, a busca ampla em cinco famílias

Método	Combinações	Melhor F1	Minutos
Grade	12	99,38%	2,2
Aleatória (mesmo orçamento)	12	99,30%	3,7



Modelos pré-treinados

Embeddings congelados e ajuste fino de um BERT reduzido

MiniLM congelado e regressão logística, validação cruzada: F1 macro 97,20%.

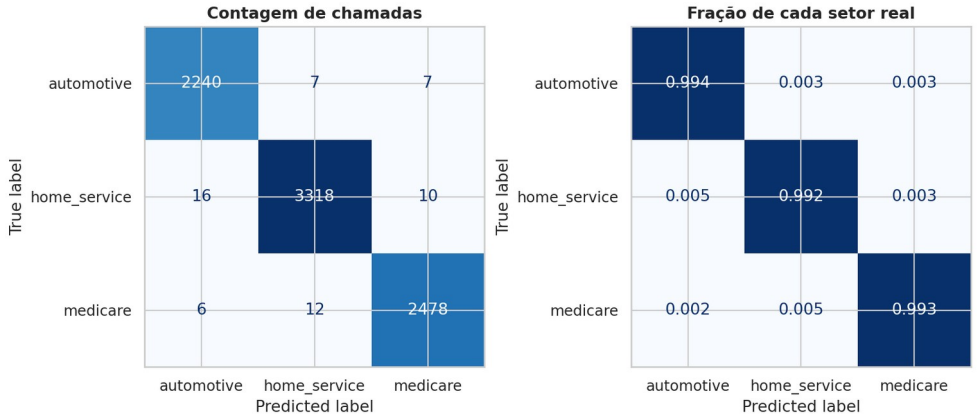
DistilBERT ajustado (1 época, 128 tokens, CPU), primeira dobra: 94,75%; o SVM na mesma dobra: 99,08%.

O ajuste fino foi feito com orçamento pequeno de CPU: mede o que cabe nesse orçamento, não o teto do BERT.

Resultado no teste

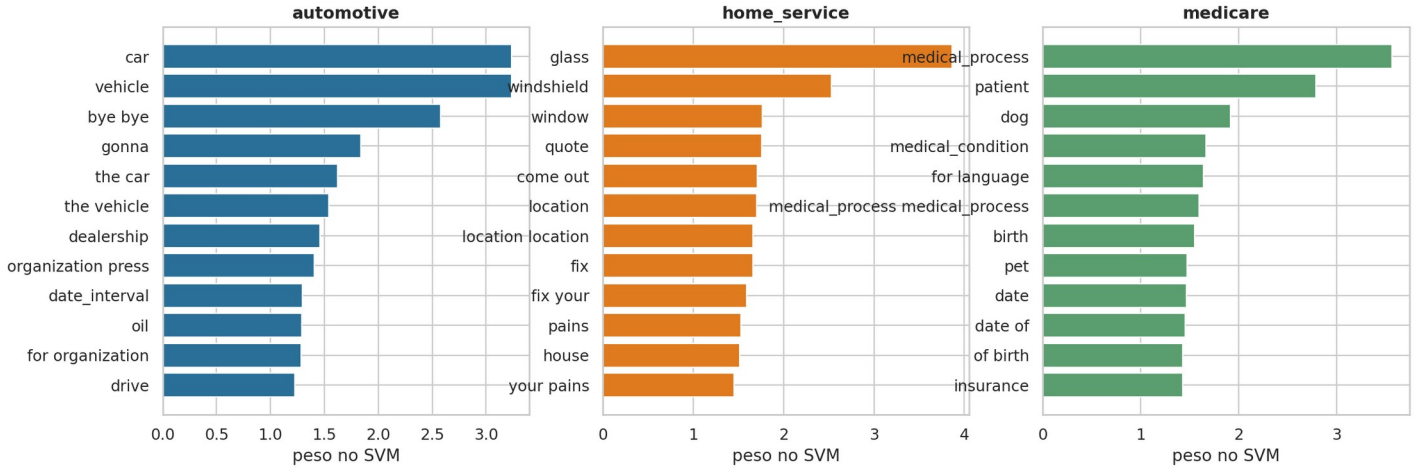
2.027 chamadas nunca usadas para escolher

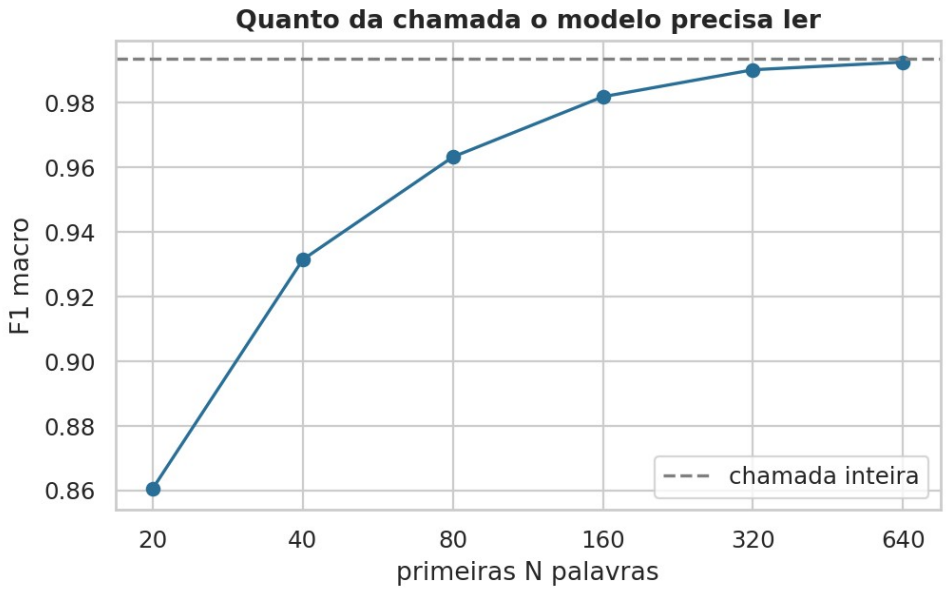
Modelo	F1 macro	Erros
melhor da busca aleatória	99,31%	14
SVM linear calibrado	99,21%	16
regressão logística	99,15%	17
combinação (pesos iguais)	99,15%	17
Naive Bayes complementar	98,42%	31
MiniLM + regressão logística	97,66%	47
DistilBERT com ajuste fino	96,43%	68



SVM linear calibrado: IC 95% do F1 macro de 98,83% a 99,56%.

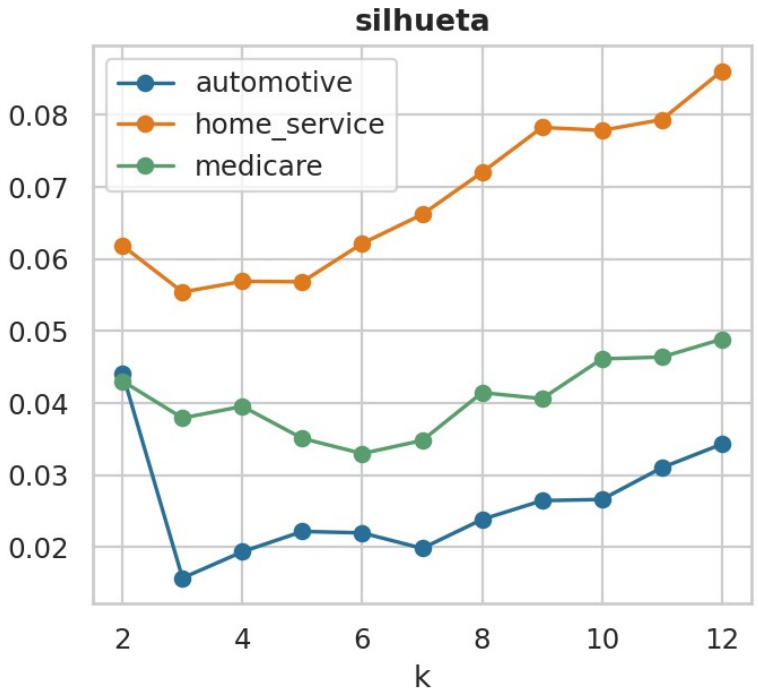
O que pesa na decisão e quanto da chamada basta

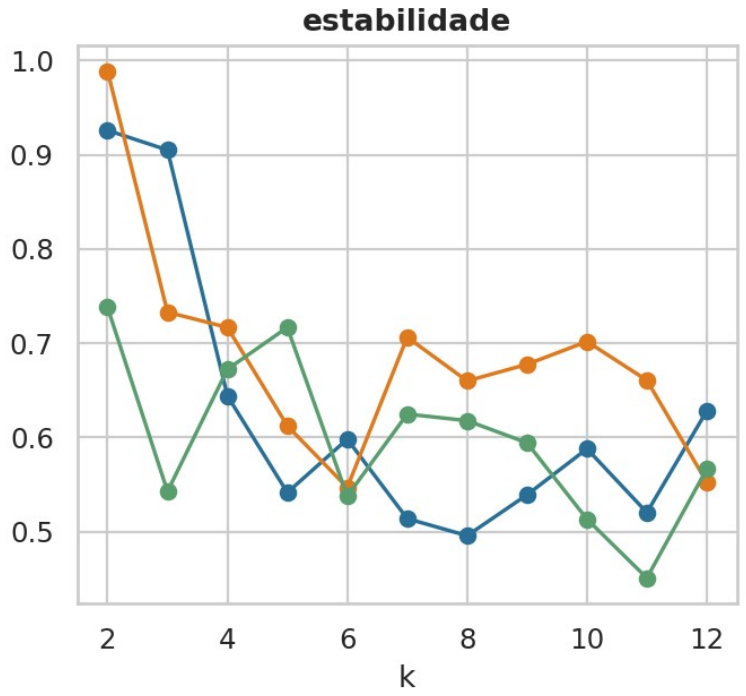


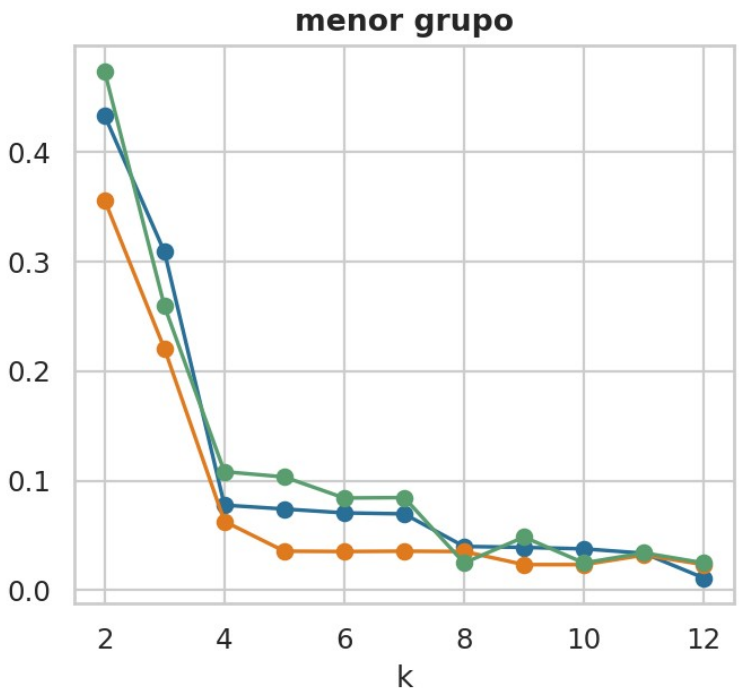


Subgrupos: quantos e por quê

Silhueta, estabilidade e tamanho do menor grupo





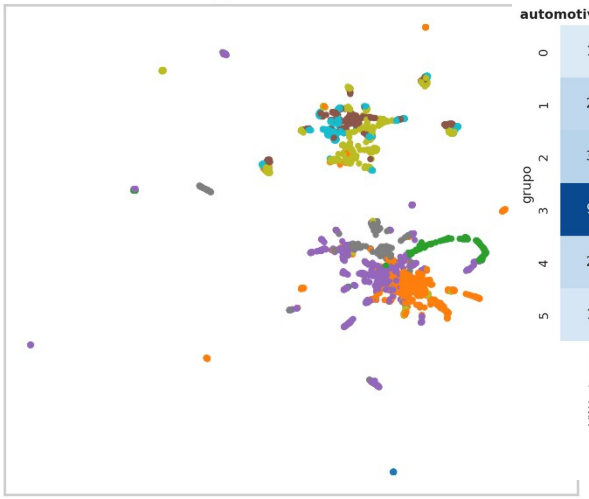


Subgrupos: o mapa e a validação por temas

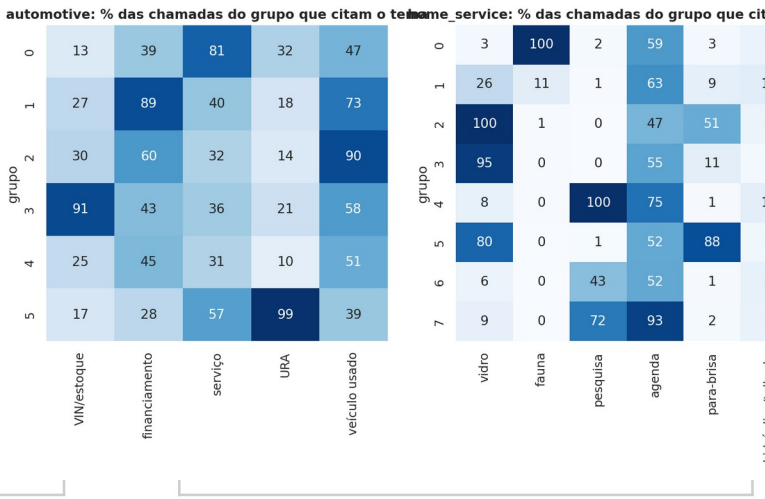
automotive: KMeans



home_service: KMeans

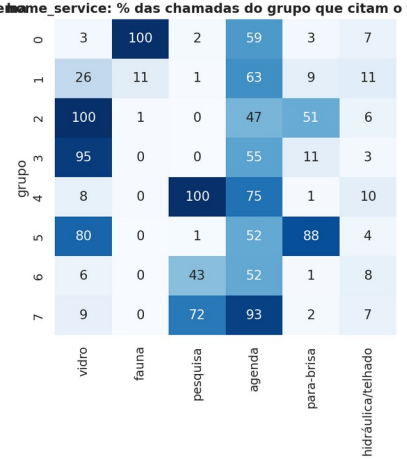


medicare: KMeans

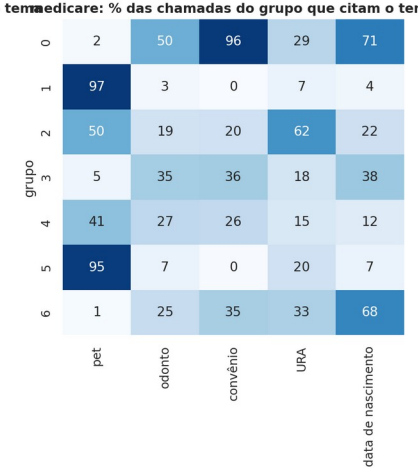


automotive: % das chamadas do grupo que citam o tema

home_service: % das chamadas do grupo que citam o tema



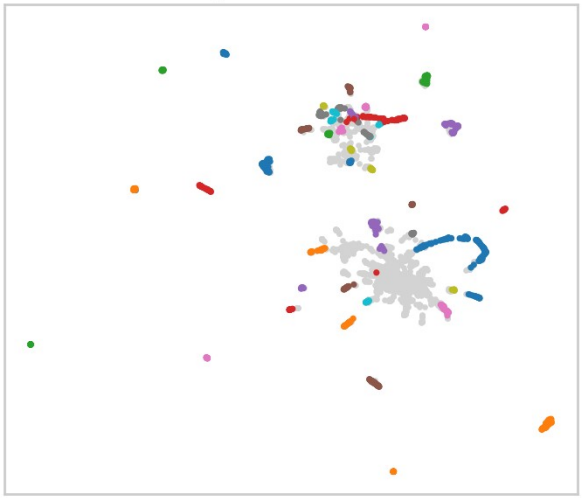
medicare: % das chamadas do grupo que citam o tema



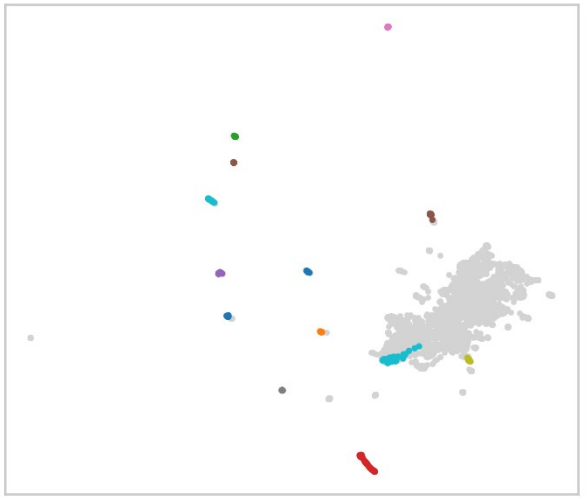
automotive: DBSCAN



home_service: DBSCAN



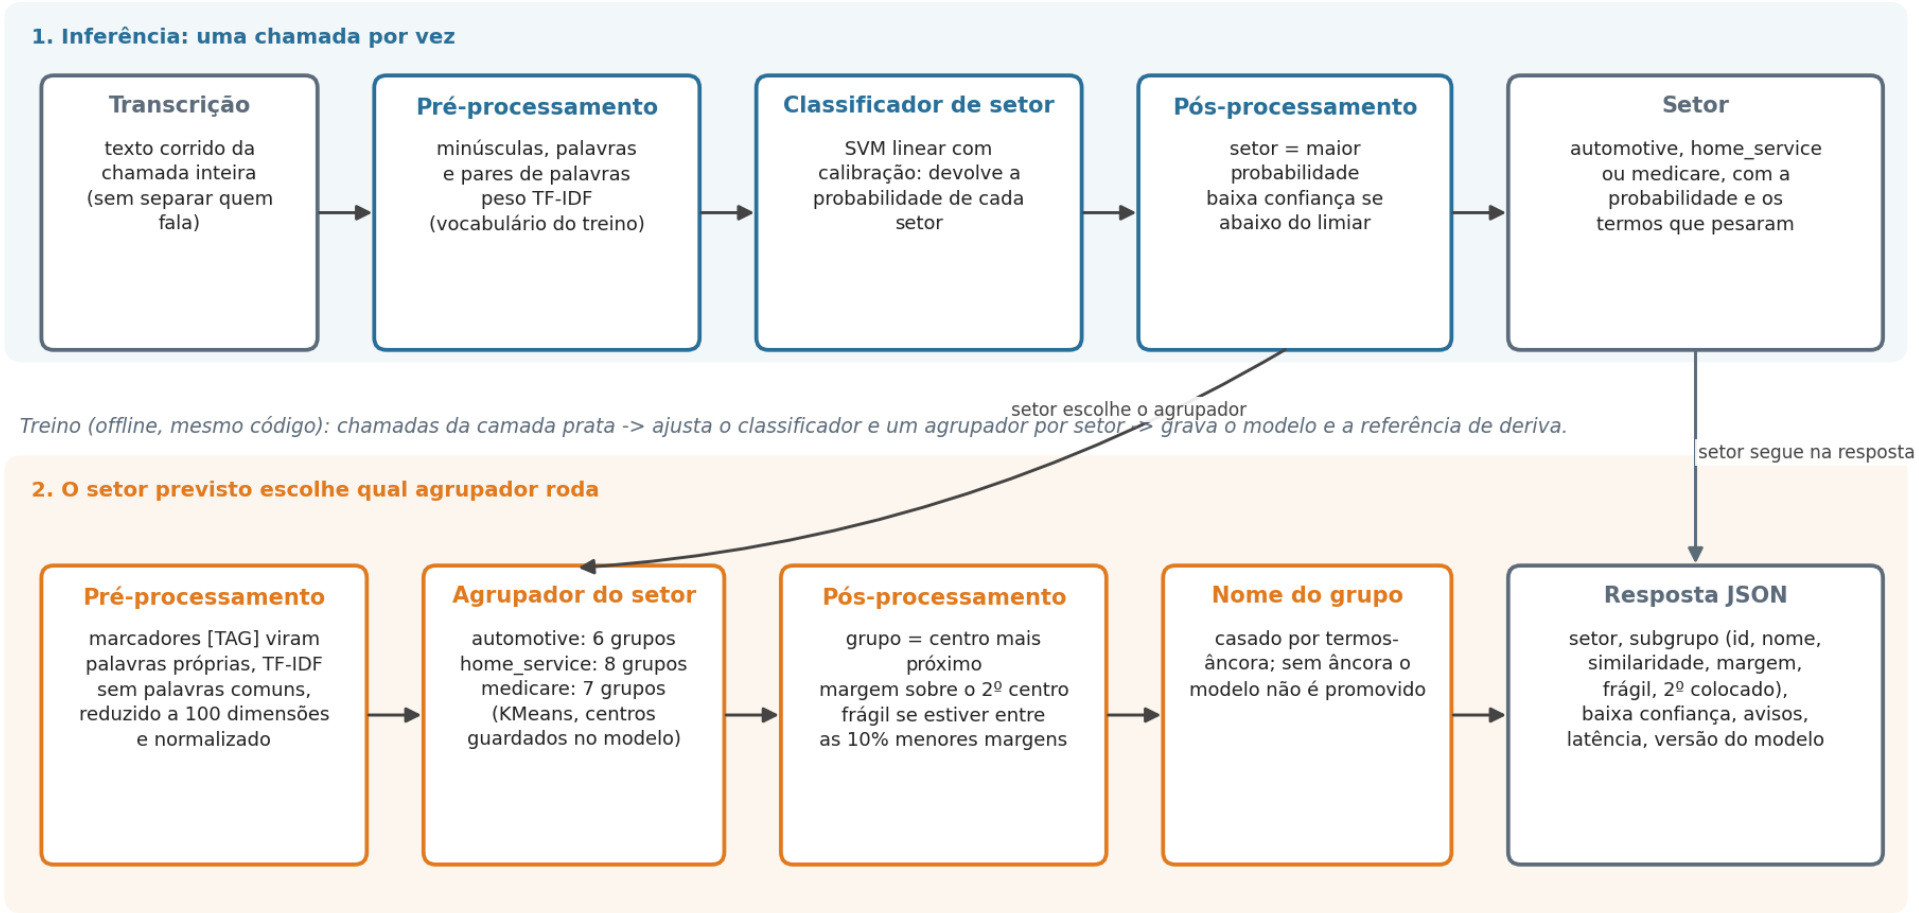
medicare: DBSCAN



Arquitetura: pipeline de modelagem

Pipeline de modelagem: da transcrição ao setor e ao subgrupo

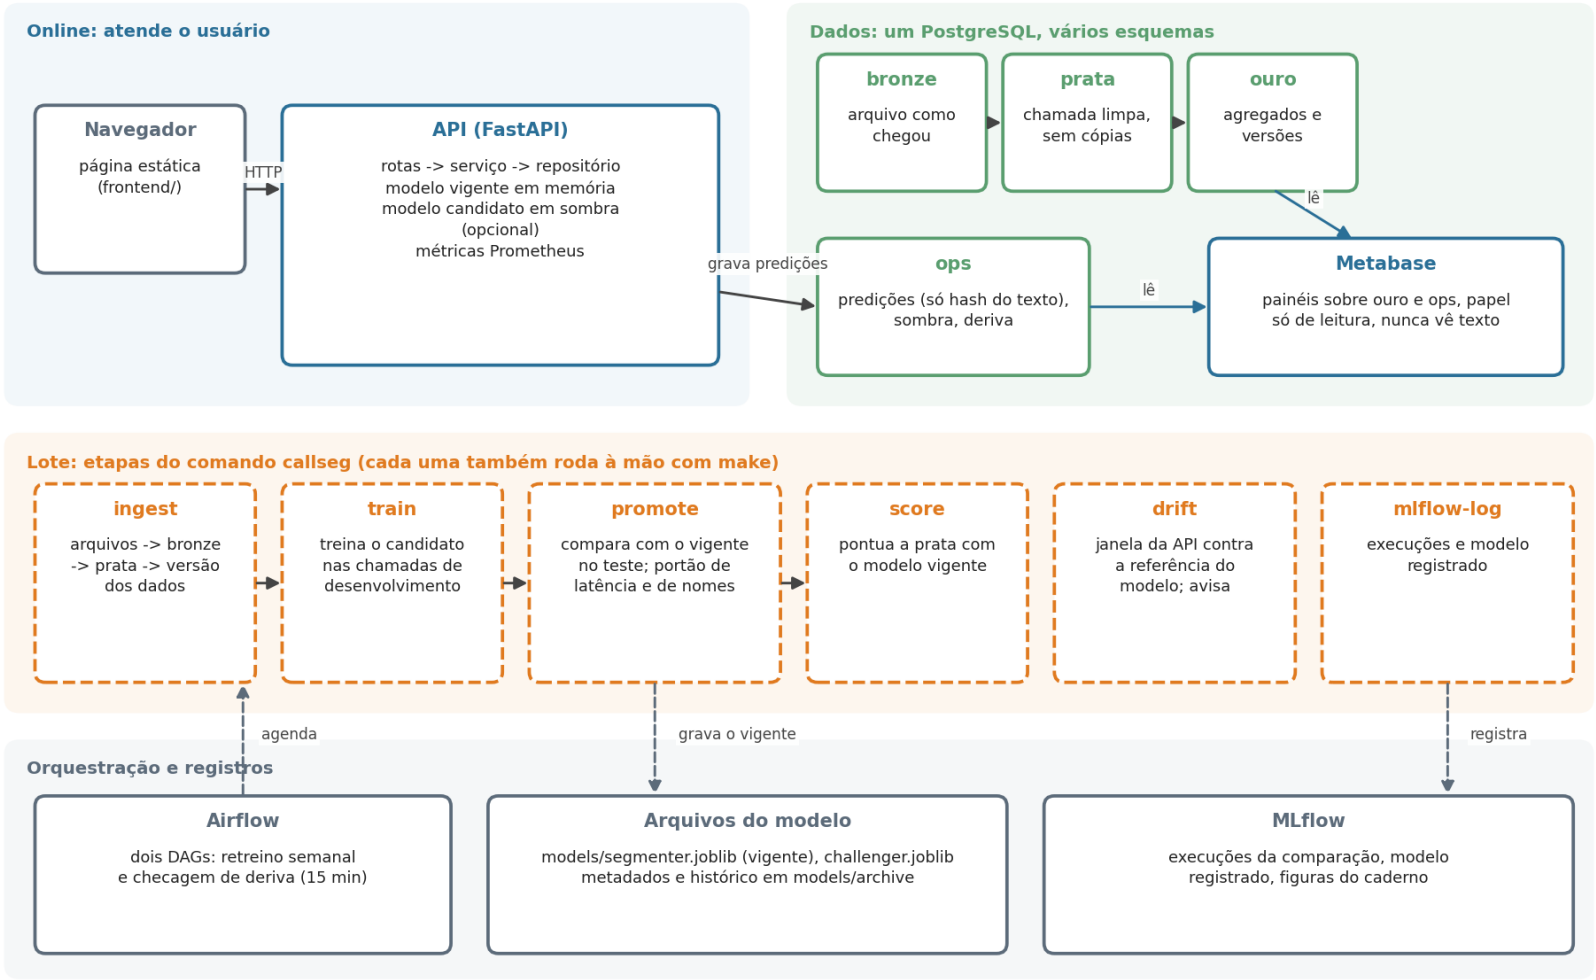
Leia da esquerda para a direita. Azul: classificação de setor (supervisionada). Laranja: subgrupo (não supervisionado). Cinza: entrada, saída e regras.



Arquitetura: plataforma

Plataforma: monolito modular com tarefas em lote agendadas

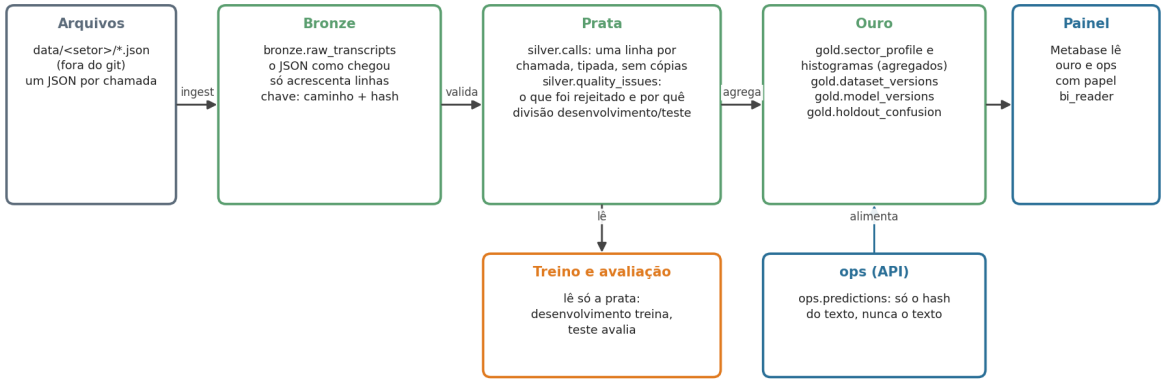
Estilo: requisição e resposta síncronas na API; o resto é lote agendado. Sem fila de eventos e sem microsserviços (ADR 0005). Tracejado: roda em lote.



Dados em camadas e ciclo de vida do modelo

Dados em camadas: do arquivo ao painel

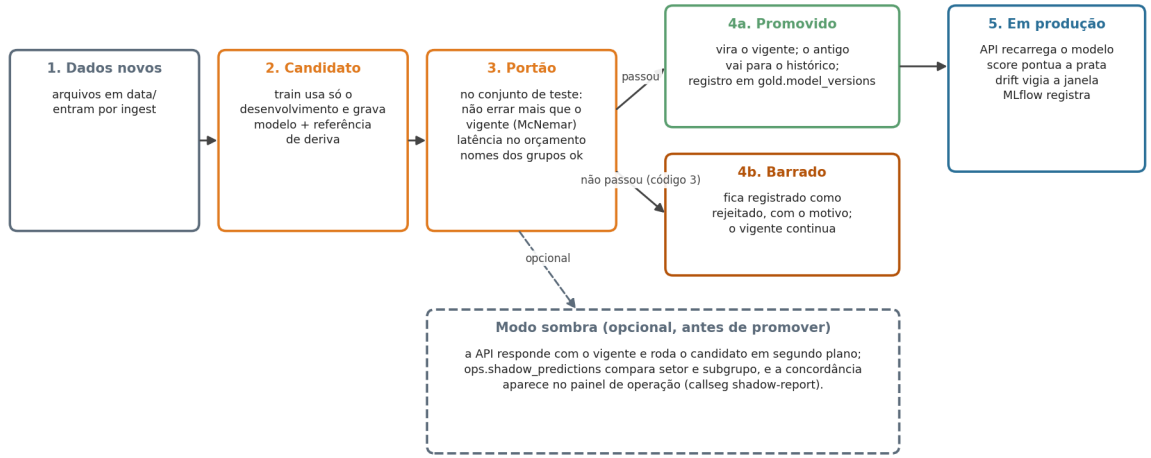
Cada camada tem um contrato. Regra: quem lê o texto (bronze, prata) é o pipeline; o painel só lê ouro e operação.



Reexecutar é seguro: a ingestão só acrescenta o que mudou, e cada versão do conjunto de dados fica registrada.

Ciclo de vida do modelo: como um modelo novo entra em produção

Toda semana (ou quando houver dados novos). O modelo vigente só é trocado se o candidato passar pelo portão.



O Airflow só agenda: cada caixa é um comando callseg que também roda à mão (make train, make promote).

Decisões, limites e próximos passos

Decisões documentadas em 13 ADRs: representação, subgrupos, nomes por âncora, privacidade, estilo de arquitetura, deriva, Airflow, dados em camadas, MLflow, exposição, backend, portão de promoção e Kubernetes.

Limites: subgrupos sem gabarito humano; atalho de metadados medido; modelo pré-treinado avaliado com orçamento pequeno.

Próximos passos: amostra rotulada por pessoas para os subgrupos, BERT com GPU, deriva por vocabulário, rótulo de qualidade por atendente quando houver falante separado.